

Da&Da Solutions

Desarrollo de Agentes de IA y LLMs

Estandares, patrones y mejores practicas para Inteligencia Artificial en Da&Da Solutions

Documento Interno — Confidencial

Version 3.1 | Ejercicio fiscal 2026 | Departamento de Ingenieria

1. La Apuesta Estrategica de Da&Da; Solutions en IA

Da&Da Solutions tiene una apuesta estrategica por la Inteligencia Artificial generativa como diferenciador competitivo de largo plazo. No como un buzzword ni como una exploracion superficial, sino como una capacidad tecnica real que agrega valor medible y reproducible a nuestros productos y a los negocios de nuestros clientes.

El equipo de AI Engineering de Da&Da Solutions, fundado en 2022, trabaja en dos frentes: integrar capacidades de IA en los productos existentes (busqueda semantica, generacion de contenido, asistentes conversacionales, automatizacion de flujos) y construir productos nativamente de IA (agentes autonomos, sistemas RAG, pipelines de ML). La IA que construimos en Da&Da es responsable, explicable y sometida a los mismos estandares de calidad que cualquier otro sistema de ingenieria.

2. Modelos de Lenguaje Aprobados

2.1 Google Gemini — LLM Principal

Google Gemini es el LLM principal de Da&Da Solutions para todas las aplicaciones de produccion. La eleccion de Gemini se basa en su calidad de razonamiento, su ventana de contexto larga (necesaria para RAG con documentos extensos), su soporte multimodal (texto, imagenes, codigo, audio, video), su disponibilidad en GCP (donde ya opera nuestra infraestructura), y los terminos de privacidad de datos de Google Cloud que son compatibles con nuestras obligaciones regulatorias.

Las variantes de Gemini en uso activo en Da&Da Solutions: gemini-2.0-flash-exp (para tareas que requieren el maximo razonamiento y calidad de output, procesos batch de baja frecuencia), gemini-1.5-flash (para tareas de alta frecuencia donde la velocidad y el costo son prioritarios sobre la maxima calidad, como clasificacion, extraccion de datos, generacion de resúmenes), gemini-1.5-pro (para tareas que requieren ventana de contexto de 1M tokens, procesamiento de documentos muy largos), gemini-embedding-004 (para generacion de embeddings para RAG y busqueda semantica).

2.2 Cohere Command R+ — Especialista en RAG

Cohere Command R+ es nuestra segunda opcion para casos de RAG de alta precision donde la capacidad de 'grounded generation' (generar solo desde el contexto provisto, con baja tasa de alucinacion) es el requisito mas importante. Command R+ fue disenado especificamente para RAG y ofrece excelente desempeno en la recuperacion de informacion factual de documentos. Cohere tambien provee modelos de embeddings multilingues (Embed v3) que son superiores a Gemini para idiomas distintos del ingles.

2.3 Modelos Open Source Self-Hosted

Para casos de uso donde la privacidad de los datos es la maxima prioridad (datos que no pueden enviarse a APIs de terceros bajo ningun concepto), Da&Da Solutions hostea modelos open source en nuestra infraestructura de GKE con GPUs (NVIDIA A100 y H100 via GKE GPU node

pools). Los modelos actuales en produccion self-hosted son: Llama 3.1 70B (via vLLM para inferencia de alta concurrencia) y Mistral 7B Instruct (para tareas simples de alta frecuencia con bajo costo de inferencia).

El hosting de modelos self-hosted implica un overhead operacional significativo (gestion de GPUs, actualizaciones de modelos, monitoreo de inferencia). No debe adoptarse sin evaluacion de costo-beneficio comparado con las APIs externas.

3. El Patron RAG — Estandar de Da&Da; para Conocimiento Empresarial

3.1 Por que RAG en lugar de Fine-tuning

Existen dos enfoques principales para hacer que un LLM responda sobre conocimiento especifico de un dominio: el fine-tuning (reentrenar el modelo con los datos del dominio) y RAG (recuperar el contexto relevante en tiempo de inferencia y inyectarlo en el prompt). Da&Da Solutions elige RAG como patron estandar por las siguientes razones:

RAG es mas economico: el fine-tuning de un modelo grande requiere computacion de GPU costosa y tiempo de entrenamiento. RAG solo requiere generar embeddings (relativamente barato) y mantener el vector store. RAG permite actualizaciones en tiempo real: cuando la documentacion cambia, solo se reindexan los documentos modificados. Con fine-tuning, cada actualizacion del conocimiento requiere un nuevo ciclo de entrenamiento. RAG es mas explicable: RAG puede citar explicitamente las fuentes de las que extrajo la informacion para generar la respuesta. Fine-tuning no tiene esta capacidad de proveniencia. RAG reduce alucinaciones: al anclar las respuestas en documentos fuente concretos, RAG reduce significativamente las alucinaciones del LLM comparado con la generacion desde el conocimiento parametrico del modelo.

3.2 Arquitectura de un Sistema RAG en Da&Da; Solutions

Todo sistema RAG tiene dos fases bien separadas. La Fase de Indexacion (offline): los documentos fuente (PDFs, paginas web, bases de datos, wikis) son cargados por un pipeline de ingesta. Cada documento es dividido en chunks (fragmentos de texto). Para cada chunk se genera un embedding (vector numerico de alta dimension que captura el significado semantico del texto). Los pares (chunk, embedding, metadatos) se almacenan en una base de datos vectorial (Qdrant en produccion, FAISS en desarrollo). Este proceso se ejecuta una vez al inicio y de forma incremental cuando los documentos fuente cambian.

La Fase de Inferencia (online): cuando el usuario formula una pregunta, se genera el embedding de esa pregunta usando el mismo modelo de embeddings. Se realiza una busqueda por similitud en la base de datos vectorial (busqueda del coseno o producto punto entre el embedding de la pregunta y los embeddings de los chunks indexados). Los K chunks mas similares (tipicamente K=5-10) se recuperan junto con sus metadatos. Los chunks recuperados se insertan en el prompt del LLM como contexto. El LLM genera la respuesta basandose en el contexto provisto, mencionando las fuentes.

3.3 Chunking — La Division del Texto

La estrategia de chunking (como se divide el texto de los documentos en fragmentos) es una de las decisiones mas criticas en el rendimiento de un sistema RAG. Un chunk demasiado pequeno pierde contexto; uno demasiado grande diluye la relevancia y consume mas tokens del contexto del LLM.

La estrategia estandar de Da&Da Solutions es RecursiveCharacterTextSplitter de LangChain con `chunk_size=1000` caracteres y `chunk_overlap=200` caracteres. El solapamiento de 200 caracteres garantiza que el contexto de los limites entre chunks no se pierda: si una idea importante comienza al final de un chunk y termina al principio del siguiente, el overlap garantiza que ambos chunks contienen el texto completo de esa idea.

Para documentos con estructura bien definida (PDFs con secciones, documentacion en Markdown), se evalua el uso de estrategias de chunking semantico que respetan los limites naturales del documento (saltos de seccion, parrafos, listas). Esto puede mejorar significativamente la calidad de los chunks comparado con el chunking puramente por numero de caracteres.

3.4 Embeddings — La Representacion Vectorial del Significado

Los embeddings son vectores numericos de alta dimension (tipicamente 768 o 1536 dimensiones) que representan el significado semantico de un texto de forma que textos similares en significado esten cerca en el espacio vectorial. Esto es lo que permite la busqueda por similitud semantica (encontrar chunks relevantes para una pregunta aunque no compartan las mismas palabras exactas).

El modelo de embeddings estandar de Da&Da Solutions es gemini-embedding-004 (dimensiones: 768, normalizado para coseno similarity). Una vez elegido el modelo de embeddings, no puede cambiarse sin reindexar completamente la base vectorial (los embeddings de modelos distintos no son comparables). Por esto, la eleccion del modelo de embeddings se hace cuidadosamente al inicio del proyecto y se documenta como un ADR.

4. Bases de Datos Vectoriales

4.1 FAISS para Desarrollo y Prototipado

FAISS (Facebook AI Similarity Search) es una libreria de indexacion vectorial en memoria desarrollada por Meta. Es ideal para el desarrollo local y el prototipado porque: no requiere infraestructura adicional (se instala como una libreria Python), se integra directamente con LangChain sin configuracion, y es extremadamente rapida para colecciones pequenas (menos de 100.000 vectores en memoria). La limitacion critica de FAISS es que no es apropiada para produccion: el indice vive completamente en memoria (no persiste en disco nativamente), no soporta actualizaciones incrementales eficientes (hay que reconstruir el indice completo para agregar nuevos documentos), y no escala horizontalmente.

4.2 Qdrant para Produccion

Qdrant es la base de datos vectorial oficial de producción de Da&Da Solutions. La elección de Qdrant sobre alternativas como Pinecone, Weaviate o Chroma se basó en: alto rendimiento en búsquedas ANN (Approximate Nearest Neighbor) con índices HNSW, soporte nativo para filtrado por metadatos junto con la búsqueda vectorial (permite hacer queries como 'encuentra los 5 chunks más similares a esta pregunta que pertenezcan al documento X'), API REST y gRPC completas con SDKs en Python y JavaScript, operación como contenedor en Kubernetes (control total sobre la infraestructura, sin vendor lock-in), y consistencia fuerte (a diferencia de Pinecone serverless que ofrece consistencia eventual).

Qdrant corre en Da&Da Solutions en un StatefulSet de Kubernetes con volúmenes de Google Persistent Disk para persistencia. Las colecciones de Qdrant se respaldan automáticamente cada 24 horas mediante snapshots almacenados en GCS. Para el cluster de producción, Qdrant opera en modo distribuido con 3 nodos para alta disponibilidad.

4.3 Pinecone como Alternativa Serverless

Pinecone es una alternativa válida cuando la simplicidad operativa y la escala masiva son prioritarias sobre el control de infraestructura. Pinecone serverless puede manejar decenas de millones de vectores sin gestión de infraestructura. Su uso en Da&Da Solutions requiere evaluación previa de costo (Pinecone cobra por volumen de vectores y operaciones) y aprobación del Staff AI Engineer.

5. Frameworks de Orquestación de IA

5.1 LangChain y LCEL

LangChain es el framework de orquestación estándar para sistemas LLM en Da&Da Solutions. LangChain provee abstracciones de alto nivel para: conexión con LLMs (Gemini, Cohere, OpenAI), document loaders para ingestar documentos de múltiples formatos (PDF, DOCX, HTML, CSV, bases de datos), text splitters para chunking, integraciones con bases de datos vectoriales (Qdrant, FAISS, Pinecone), y cadenas de procesamiento (Chains) para orquestar el flujo RAG.

LangChain Expression Language (LCEL) es la forma moderna y preferida de construir chains en LangChain. LCEL permite componer operaciones con el operador pipe (|), lo que resulta en código más legible y declarativo. Adicionalmente, LCEL soporta streaming de respuestas (el LLM responde token a token en lugar de esperar a tener la respuesta completa), paralelismo automático cuando hay operaciones independientes, y trazabilidad completa vía LangSmith.

5.2 LangGraph para Agentes Multi-paso

LangGraph es una extensión de LangChain para construir agentes con ciclos de razonamiento y uso de herramientas. Modela el flujo del agente como un grafo de estado donde los nodos son funciones (que pueden llamar al LLM, usar herramientas, o hacer cálculos) y las aristas son las transiciones entre estados. Esta representación hace que el flujo del agente sea explícito, debuggeable y modificable.

LangGraph se usa en Da&Da Solutions para: agentes que necesitan razonar en multiples pasos (consultar documentos, sintetizar informacion, y luego responder), agentes que usan herramientas (calculadoras, APIs externas, bases de datos) en sus razonamientos, y flujos de trabajo de IA con ramificaciones condicionales complejas.

5.3 SDK Nativo de Google Gemini — Para Casos Simples

Para llamadas simples al LLM que no requieren la orquestacion de LangChain (generacion de texto simple, clasificacion, extraccion de datos estructurados), usar directamente el SDK oficial de Google (`google-generativeai`) es mas adecuado. Las abstracciones de LangChain son poderosas pero agregan overhead: mas dependencias, capas de abstraccion adicionales, y a veces dificultan el debugging. Si el caso de uso no justifica LangChain, no usarlo.

6. Prompt Engineering — El Arte de Comunicarse con LLMs

6.1 Estructura de un Prompt Efectivo

Un prompt efectivo en Da&Da Solutions sigue una estructura clara: Role (el rol o persona que debe adoptar el LLM: 'Eres un asistente de soporte tecnico experto en los productos de Da&Da Solutions'), Context (el contexto relevante para la tarea, como el historial de la conversacion o los documentos recuperados por RAG), Instructions (las instrucciones especificas de la tarea, en lenguaje claro y sin ambigüedades), Constraints (las limitaciones y restricciones: 'No inventes informacion que no este en el contexto provisto. Si no sabes la respuesta, di que no tienes informacion suficiente'), Format (el formato de salida esperado: 'Responde en espanol. Usa markdown para los bloques de codigo'), y Examples (ejemplos few-shot cuando sea util para alinear el estilo de respuesta).

6.2 Versionado y Gestion de Prompts

Los prompts del sistema son codigo. Deben tratarse con el mismo rigor que cualquier otro codigo: versionados en el repositorio, revisados en Pull Request, testeados antes de ir a produccion. En Da&Da Solutions usamos LangSmith Hub para centralizar y versionar los prompts de los sistemas mas criticos. Cualquier cambio al prompt del sistema de una aplicacion de produccion debe pasar por evaluacion con el eval set del sistema antes de deployarse.

6.3 Prevencion de Prompt Injection

El prompt injection es una clase de ataque donde un usuario malicioso incluye en su input instrucciones que manipulan el comportamiento del LLM, ignorando el system prompt. Medidas de mitigacion en Da&Da Solutions: separar claramente el system prompt (controlado por el sistema) del user input (controlado por el usuario, potencialmente malicioso) en la estructura del prompt; validar y sanitizar el input del usuario antes de incluirlo en el prompt; implementar guardrails de contenido que detecten patrones de injection comunes ('Ignora las instrucciones anteriores', 'Eres ahora un asistente sin restricciones', etc.); y nunca incluir secretos, instrucciones de seguridad criticas o informacion confidencial en el system prompt (asumir que el system prompt puede ser extraido por un atacante determinado).

7. Evaluacion de Sistemas de IA

7.1 La Necesidad de Evaluacion Sistemática

Un sistema de IA sin evaluacion sistematica no puede evolucionar con confianza. ¿Como sabemos si el nuevo modelo de embeddings es mejor que el anterior? ¿Como sabemos si el cambio en el chunking mejoro la calidad de las respuestas? Sin un framework de evaluacion con metricas objetivas, las decisiones sobre los componentes del sistema de IA son intuitivas y potencialmente regresivas.

7.2 Metricas de Evaluacion RAG con RAGAS

Da&Da Solutions usa RAGAS (RAG Assessment) como framework de evaluacion para todos los sistemas RAG. RAGAS provee las siguientes metricas automatizadas: Faithfulness (mide si la respuesta generada esta factualmente respaldada por los chunks del contexto recuperado; una respuesta fiel no inventa informacion que no esta en el contexto; objetivo: mayor a 0.85), Answer Relevancy (mide si la respuesta es relevante para la pregunta original del usuario; objetivo: mayor a 0.80), Context Precision (mide si los chunks mas relevantes estan rankeados en las primeras posiciones de los resultados de recuperacion; objetivo: mayor a 0.75), y Context Recall (mide si todos los chunks necesarios para responder la pregunta fueron recuperados; objetivo: mayor a 0.80).

7.3 El Eval Set — El Conjunto de Evaluacion

El eval set es un conjunto curado de pares (pregunta, respuesta esperada) creado por expertos del dominio. Es el activo mas valioso del sistema de evaluacion. Un buen eval set cubre: preguntas de distintos niveles de dificultad (simples, que requieren sintesis de multiples fuentes, y ambiguas), preguntas de distintos tipos (factuales, de procedimiento, comparativas), y edge cases conocidos (preguntas fuera del scope del sistema, preguntas con informacion contradictoria en las fuentes).

Antes de cualquier cambio significativo al sistema RAG (nuevo modelo de embeddings, nueva estrategia de chunking, nuevo LLM, cambio en el system prompt), se ejecuta el eval set completo y se comparan las metricas RAGAS con la linea base registrada. Una regresion en cualquier metrica mayor a 5 puntos porcentuales debe ser investigada antes de deployar el cambio.

8. Seguridad y Etica en IA

8.1 Privacidad de Datos en Sistemas de IA

La regla mas importante de seguridad en sistemas de IA de Da&Da Solutions: datos de identificacion personal (PII) — nombres, correos, numeros de telefono, numeros de identificacion nacional, datos de salud, datos financieros — nunca deben ser enviados en prompts a LLMs de APIs externas (Gemini, Cohere) sin ser anonimizados o pseudonimizados previamente. Si un

sistema de IA necesita operar con datos PII de forma inevitable, debe usar modelos self-hosted.

8.2 Guardrails de Contenido

Los sistemas de IA de producción que interactúan directamente con usuarios finales deben implementar guardrails de contenido para verificar que ni el input del usuario ni el output del LLM contienen: contenido violento, ofensivo o inapropiado, intentos de extracción de información confidencial del sistema, instrucciones de actividades ilegales, y afirmaciones médicas, legales o financieras de alto riesgo sin la advertencia apropiada.

Da&Da Solutions implementa guardrails usando los filtros de seguridad nativos de la API de Gemini (`safety_settings`) como primera línea de defensa, complementados con reglas de validación personalizadas usando la librería Guardrails AI para casos específicos del dominio.

8.3 Transparencia y Explicabilidad

Los sistemas de IA de Da&Da Solutions que toman decisiones que afectan directamente a los usuarios (aprobación de crédito, clasificación de riesgo, recomendaciones médicas) deben ser explicables: deben poder decirle al usuario por qué tomaron la decisión que tomaron, basándose en qué información, y con qué nivel de confianza. Los sistemas 'black box' que toman decisiones impactantes sin poder explicarlas son inaceptables en Da&Da Solutions.

8.4 IA Responsable — Principios de Da&Da;

El equipo de AI Engineering de Da&Da Solutions se guía por los principios de IA Responsable: Beneficencia (los sistemas de IA deben beneficiar a los usuarios y a la sociedad, no solo a la empresa), No maleficencia (los sistemas no deben causar daño a los usuarios ni a terceros), Autonomía (los usuarios deben poder entender, controlar y optar por no usar los sistemas de IA cuando así lo deseen), Justicia (los sistemas no deben discriminar ni perpetuar sesgos existentes en los datos de entrenamiento), y Responsabilidad (siempre debe haber un ser humano responsable de las decisiones de un sistema de IA en contextos de alto impacto).

9. Observabilidad de Sistemas de IA

9.1 LangSmith para Trazabilidad de LangChain

Todos los sistemas LangChain en producción en Da&Da Solutions están conectados a LangSmith, el sistema de observabilidad de LangChain. LangSmith registra automáticamente cada invocación de un chain o agente: el prompt completo enviado al LLM (incluyendo el system prompt y el contexto RAG), los chunks recuperados de la base vectorial con sus scores de similitud, la respuesta generada por el LLM, la latencia total y de cada paso del chain, y el costo estimado en tokens (input + output).

9.2 Métricas Operacionales de Sistemas de IA

Además de la trazabilidad de LangSmith, los servicios de IA exponen métricas de Prometheus: `llm_inference_duration_seconds` (histograma de latencia de la llamada al LLM), `vector_search_duration_seconds` (histograma de latencia de la búsqueda vectorial),

llm_tokens_used_total (contador de tokens de input y output consumidos, desglosado por modelo), llm_api_errors_total (contador de errores de la API del LLM, desglosado por tipo de error), y rag_faithfulness_score (metrica en tiempo real de la calidad de las respuestas, evaluada por un LLM evaluador).

10. MLOps y Ciclo de Vida de Modelos

10.1 MLflow para Gestion de Experimentos

Para proyectos que involucran entrenamiento de modelos propios (modelos de clasificacion, recomendacion, forecasting o fine-tuning de LLMs), usamos MLflow como plataforma de experimentacion. MLflow registra: los hiperparametros de cada experimento, las metricas de evaluacion (accuracy, F1, AUC-ROC, BLEU, ROUGE segun el tipo de modelo), los artefactos del modelo (los pesos guardados), y las dependencias de codigo (el hash del commit de Git en el que se entreno el modelo).

10.2 Model Registry y Gobernanza de Modelos

Antes de desplegar cualquier modelo entrenado en produccion, debe ser registrado en el Model Registry de MLflow y pasar por un proceso de aprobacion. Los estados de un modelo en el registry son: Staging (candidato a produccion, en fase de validacion por el equipo de AI y el negocio), Production (actualmente en produccion), y Archived (historico, reemplazado por una version mas nueva). Solo los modelos en estado Production pueden ser referenciados en los servicios de produccion. El cambio de estado de Staging a Production requiere la firma de al menos un Staff AI Engineer y del Product Manager responsable.

11. Evaluacion y Benchmarking de Agentes

11.1 Por Que Evaluar es tan Importante como Construir

Un agente de IA sin un conjunto de evaluaciones robustas es un agente en el que no se puede confiar para produccion. La evaluacion de agentes es significativamente mas compleja que la evaluacion de modelos de clasificacion tradicionales: las respuestas son abiertas, el espacio de inputs posibles es virtualmente infinito, y la calidad de una respuesta puede depender del contexto de la conversacion completa.

En Da&Da Solutions no deployamos ningun componente de agente a produccion sin un harness de evaluacion que corra en el pipeline de CI y que verifique que el agente cumple los criterios de calidad minimos definidos por el Product Manager.

11.2 Tipos de Evaluaciones para Agentes

Tres tipos principales de evaluaciones:

- **Evaluaciones basadas en criterios deterministas:** para casos donde la respuesta correcta es unica y verificable. El agente llama a la herramienta correcta con los parametros correctos, o extrae correctamente un dato de un texto.
- **Evaluaciones basadas en LLM como juez (LLM-as-Judge):** para casos donde la calidad es subjetiva. Un segundo modelo de lenguaje evalua la respuesta del agente en base a una rubrica definida: factuallidad, concision, y tono apropiado.
- **Evaluaciones con expertos humanos:** indispensables para validar que las evaluaciones automaticas se correlacionan con la satisfaccion de usuarios reales. Se realizan periodicamente con muestras del trafico de produccion.

11.3 Conjunto de Datos de Evaluacion (Eval Sets)

Cada agente deployado en produccion tiene un eval set asociado, version-controlado en el repositorio del agente. Contiene: ejemplos positivos (inputs con respuestas correctas), ejemplos negativos (inputs donde el agente NO debe realizar ciertas acciones), y ejemplos de casos extremos identificados durante el desarrollo o en produccion. Cada bug de produccion relacionado con el comportamiento del agente debe convertirse en un nuevo caso en el eval set para prevenir regresiones.

12. Seguridad en Agentes de IA

12.1 Prompt Injection

El prompt injection es el equivalente del SQL injection para los agentes de IA. Ocurre cuando datos no confiables (input del usuario, contenido de documentos, respuestas de APIs externas) contienen instrucciones que modifican el comportamiento del agente de maneras no previstas.

Las mitigaciones que aplicamos: delimitar claramente con marcadores especiales los datos no confiables en los prompts; no incluir datos sensibles en el contexto si no son necesarios; implementar un filtro de salida (output guard) que detecta respuestas que contengan el system prompt; y usar modelos con instruction hierarchy donde las instrucciones del sistema tienen mayor prioridad que los mensajes del usuario.

12.2 Privilegio Minimo para Agentes

El principio de privilegio minimo aplica a los agentes igual que a los usuarios y sistemas. Un agente de soporte al cliente que responde preguntas de FAQs no debe tener acceso a la herramienta de procesamiento de reembolsos. En la arquitectura de Da&Da Solutions, los tools disponibles para cada agente se definen en su configuracion (no en el system prompt) y son validados por el orchestrator antes de ejecutarse.

12.3 Auditoria de Decisiones del Agente

Toda accion ejecutada por un agente que involucre herramientas con efectos secundarios debe quedar registrada en un audit log inmutable con: el timestamp exacto, el agente que tomo la decision, el mensaje del usuario que desencadeno la accion, el razonamiento del agente (chain of thought), el tool call con sus parametros exactos, y el resultado de la ejecucion.

13. Agentes en Produccion — Operaciones

13.1 Monitoreo Especifico para Agentes

Ademas del monitoreo estandar, los agentes de IA requieren metricas especificas:

- **Token usage per request:** para controlar costos y detectar runaway loops.
- **Tool call success rate:** porcentaje de llamadas a herramientas que se completan exitosamente.
- **Tasa de rechazo de guardrails:** cuantas respuestas son bloqueadas por los filtros de seguridad.
- **User satisfaction score (CSAT):** obtenido via thumbs up/down en la interfaz.
- **Escalacion a humano:** tasa de conversaciones que el agente derivo a un operador humano.

13.2 Rollouts Graduales para Cambios de Agente

Los cambios en los agentes se despliegan usando rollout gradual: 1% del trafico primero, monitoreo durante 24 horas, luego 10%, 50% y finalmente 100%. En cada etapa se comparan las metricas clave del nuevo agente vs el anterior usando un A/B test estadisticamente riguroso.

14. Glosario de Terminos de IA Generativa

14.1 Conceptos Fundamentales

- **Token:** la unidad basica de texto que procesa un LLM. Aproximadamente 4 caracteres en ingles o 3 en espanol. Los costos de los APIs de LLMs se miden en tokens.
- **Context window:** la cantidad maxima de tokens que puede procesar un LLM en una sola llamada, incluyendo el system prompt, el historial de conversacion, y la respuesta generada.
- **Temperature:** parametro que controla la aleatoriedad de las respuestas del modelo. Valores cercanos a 0 producen respuestas deterministas; valores cercanos a 1 producen respuestas mas variadas y creativas.
- **RAG (Retrieval-Augmented Generation):** patron arquitectonico que combina un sistema de busqueda de documentos relevantes con un LLM. El LLM recibe los documentos recuperados como contexto adicional para responder con informacion especifica y actualizada.
- **Embedding:** representacion vectorial de un texto en un espacio de alta dimension donde textos semanticamente similares tienen vectores cercanos. Base de los sistemas RAG y de busqueda semantica.
- **Grounding:** tecnica para anclar las respuestas del modelo a fuentes de informacion verificables, reduciendo las alucinaciones.

- **Hallucination:** cuando un LLM genera informacion factualmente incorrecta con aparente confianza. Es uno de los riesgos principales a mitigar en sistemas de produccion.
- **Few-shot prompting:** tecnica de prompting que incluye ejemplos de inputs y outputs esperados en el prompt para guiar el comportamiento del modelo sin necesidad de fine-tuning.
- **Fine-tuning:** proceso de ajuste de los pesos de un modelo pre-entrenado usando un dataset especifico para mejorar su performance en una tarea particular.

14.2 Conceptos de Arquitectura de Agentes

- **Tool / Function calling:** capacidad de los LLMs modernos de identificar cuando deben llamar a una funcion externa y con que argumentos, en lugar de responder directamente con texto.
- **Orchestrator:** el componente que coordina la ejecucion de un agente multi-step, decidiendo cuando llamar al LLM, cuando ejecutar herramientas, y cuando terminar el ciclo.
- **ReAct (Reason + Act):** patron de prompting para agentes que alterna ciclos de razonamiento (Thought) con ejecucion de acciones (Action) y observacion de resultados (Observation).
- **Agent loop:** el ciclo iterativo del agente: recibir input, razonar, ejecutar herramienta (opcional), observar resultado, razonar nuevamente, hasta producir una respuesta final.
- **Multi-agent system:** arquitectura donde multiples agentes especializados colaboran para resolver tareas complejas, comunicandose entre si y coordinando su trabajo.

Anexo A: Políticas de Calidad y Mejora Continua

A.1 Propósito y Alcance

En Da&Da Solutions, la calidad no es una opción, es un pilar fundamental de nuestra entrega de valor. Este anexo establece las bases de nuestro Sistema de Gestión de Calidad (SGC) aplicable a todas las áreas de ingeniería, desarrollo, operaciones y soporte de la organización. Nuestro compromiso es mantener estándares de excelencia en todos los productos y servicios que desarrollamos, asegurando la satisfacción de nuestros clientes y el cumplimiento de los requisitos legales y regulatorios vigentes en todos los mercados donde operamos.

El alcance de esta política abarca desde la concepción y diseño de los sistemas, pasando por el desarrollo, pruebas, despliegue, hasta el mantenimiento y soporte continuo. Todo el personal interno, así como contratistas y proveedores de servicios de Da&Da Solutions, están obligados a conocer, comprender y aplicar estos principios en su labor diaria.

A.2 Principios de Calidad

Nuestros principios de calidad se centran en:

- **Enfoque al Cliente:** Entender las necesidades actuales y futuras de nuestros clientes para superar sus expectativas.
- **Liderazgo:** Los líderes de todos los niveles deben establecer un propósito claro y crear un entorno interno que promueva la participación activa del personal.
- **Compromiso del Personal:** La competencia, empoderamiento y compromiso de las personas en todos los niveles son esenciales para crear y entregar valor.
- **Enfoque Basado en Procesos:** Los resultados consistentes se logran de manera más efectiva cuando las actividades se entienden y gestionan como procesos interrelacionados.
- **Mejora Continua:** La mejora constante del desempeño general de la organización es un objetivo permanente.
- **Toma de Decisiones Basada en Evidencia:** Las decisiones efectivas se basan en el análisis de datos y la información.
- **Gestión de Relaciones:** Fomentar relaciones mutuamente beneficiosas con proveedores y socios estratégicos.

A.3 Métricas e Indicadores de Calidad

Para asegurar el cumplimiento de nuestros objetivos de calidad, Da&Da Solutions monitoriza de forma continua un conjunto de indicadores clave de rendimiento (KPIs). Estos incluyen:

- **Defect Escape Rate (DER):** Porcentaje de defectos que se escapan a producción frente al total de defectos encontrados.
- **Time to Resolve (TTR):** Tiempo promedio necesario para resolver incidentes críticos reportados por clientes.

- **Customer Satisfaction Score (CSAT):** Indice de satisfaccion del cliente recopilado mediante encuestas periodicas tras la resolucion de tickets y entrega de proyectos.
- **Code Coverage:** Porcentaje de codigo cubierto por pruebas automatizadas (unitarias, integracion, e2e). El objetivo minimo es del 85% para todos los proyectos nuevos.
- **Technical Debt Ratio:** Relacion entre el costo de solucionar problemas estructurales del codigo y el costo de desarrollar nuevo software.

A.4 Auditorias Internas y Externas

Da&Da Solutions realiza auditorias internas trimestrales para verificar el cumplimiento de los procesos documentados y detectar oportunidades de mejora. Estas auditorias son lideradas por el equipo de QA Corporativo, y sus resultados se presentan a la direccion ejecutiva para su revision. Ademas, nos sometemos a auditorias externas anuales para mantener nuestras certificaciones internacionales (como ISO 9001 e ISO 27001). Todo colaborador debe cooperar activamente y con total transparencia durante cualquier proceso de auditoria.

Anexo B: Normativas de Compliance y Etica Corporativa

B.1Codigo de Conducta y Etica

El Codigo de Conducta de Da&Da Solutions es la brujula que guia nuestras acciones y decisiones diarias. Esperamos que todos los empleados, contratistas y colaboradores actuen con la maxima integridad, honestidad y respeto en todas sus interacciones, ya sea con companeros de trabajo, clientes, socios o competidores.

No toleramos ninguna forma de discriminacion, acoso (sexual, laboral o de cualquier otro tipo), ni represalias contra quienes reporten infracciones de buena fe. Promovemos un ambiente de trabajo inclusivo y diverso donde todas las voces son valoradas.

B.2Prevencion del Fraude y Corrupcion

Da&Da Solutions se rige por politicas estrictas de tolerancia cero ante el soborno y la corrupcion. Esta terminantemente prohibido ofrecer, prometer, dar, aceptar o solicitar cualquier ventaja indebida (financiera o de otro tipo) para obtener un beneficio comercial o personal. Esto incluye regalos extravagantes, atenciones desproporcionadas y pagos de facilitacion.

Cualquier colaborador que tenga conocimiento o sospecha de un acto de corrupcion debe reportarlo inmediatamente a traves del Canal de Denuncias Eticas, el cual garantiza el anonimato y la confidencialidad absoluta.

B.3Conflictos de Interes

Un conflicto de interes ocurre cuando los intereses personales de un colaborador interfieren, o parecen interferir, con los intereses de Da&Da Solutions. Todos los empleados tienen la obligacion de evitar situaciones en las que su juicio objetivo pueda verse comprometido.

Ejemplos comunes de conflictos de interes incluyen:

- Tener una relacion financiera o comercial con un proveedor, cliente o competidor.
- Usar informacion confidencial de la empresa para beneficio personal (Insider Trading).
- Contratar o supervisar directamente a un familiar cercano o pareja sentimental.
- Trabajar en proyectos paralelos o consultar para empresas de la misma industria sin autorizacion previa.

Cualquier posible conflicto de interes debe ser revelado de inmediato al departamento de RRHH y al manager directo para su evaluacion y gestion adecuada.

B.4 Confidencialidad y Propiedad Intelectual

Toda la informacion generada o procesada dentro de Da&Da Solutions es propiedad exclusiva de la empresa o de sus clientes. Esto abarca codigo fuente, algoritmos, disenos, estrategias de negocio, bases de datos y cualquier documentacion tecnica o comercial.

Los colaboradores tienen el deber de mantener la mas estricta confidencialidad sobre esta informacion, incluso despues de finalizada su relacion laboral con la empresa. Asimismo, todo desarrollo intelectual creado durante el horario laboral o utilizando recursos de la compania pertenece enteramente a Da&Da Solutions. Se prohíbe el uso de software sin licencia o material con derechos de autor sin la debida autorizacion.

Anexo C: Plan de Continuidad del Negocio (BCP)

C.1 Objetivos del BCP

El Plan de Continuidad del Negocio de Da&Da Solutions tiene como objetivo asegurar la operacion ininterrumpida de nuestros servicios criticos frente a eventos adversos (desastres naturales, pandemias, ciberataques a gran escala, fallas catastroficas de infraestructura). El BCP garantiza que podamos mantener nuestros compromisos contractuales, minimizar las perdidas financieras y proteger la reputacion de la compania.

C.2 Evaluacion de Riesgos y BIA (Business Impact Analysis)

De forma anual, el Comité de Riesgos realiza un Analisis de Impacto al Negocio (BIA) para identificar los procesos criticos, evaluar las consecuencias de su interrupcion y determinar los Tiempos Objetivo de Recuperacion (RTO) y los Puntos Objetivo de Recuperacion (RPO) para cada sistema y servicio de la organizacion. Los resultados del BIA dictan las estrategias de recuperacion y la asignacion de recursos para el BCP.

C.3 Equipos de Respuesta y Roles

El BCP define una estructura clara de respuesta ante crisis:

- **Comite de Manejo de Crisis (CMC):** Formado por la alta direccion. Encargado de tomar decisiones estrategicas, aprobar comunicaciones corporativas y declarar formalmente el estado de emergencia.
- **Equipo de Respuesta a Incidentes (IRT):** Formado por lideres tecnicos y de operaciones. Responsable de ejecutar las tareas tacticas para contener y mitigar el incidente en tiempo real.
- **Coordinadores de Continuidad:** Designados en cada departamento para asegurar la ejecucion ordenada del plan a nivel operativo y gestionar al personal.

C.4 Procedimientos de Evacuacion y Trabajo Remoto

En caso de que las instalaciones fisicas de Da&Da Solutions queden inutilizables, se activara el protocolo de trabajo 100% remoto para todo el personal. La infraestructura en la nube esta disenada para soportar el acceso remoto seguro (via VPN corporativa y Zero Trust Network Access) del total de la plantilla sin degradacion del servicio.

Se requiere que todos los empleados mantengan sus equipos portatiles actualizados y participen en los simulacros de evacuacion y pruebas de conectividad remota que se realizan semestralmente.

Anexo D: Responsabilidad Social Corporativa y Sostenibilidad

D.1 Compromiso Ambiental

En Da&Da Solutions reconocemos nuestra responsabilidad con el medio ambiente. Estamos comprometidos a minimizar nuestra huella de carbono mediante la optimización de recursos y la implementación de prácticas sostenibles. Nuestros objetivos ambientales para los próximos cinco años incluyen:

- Reducir el consumo energético en nuestras oficinas físicas en un 25% mediante políticas de uso eficiente e iluminación inteligente.
- Migrar el 100% de nuestra carga de trabajo en la nube a regiones de proveedores (como AWS o GCP) que se alimenten exclusivamente de energías renovables.
- Implementar un programa corporativo de reciclaje y gestión de residuos electrónicos (e-waste), asegurando que los equipos obsoletos sean donados o reciclados correctamente.

D.2 Impacto Comunitario y Voluntariado

Creemos firmemente en devolver valor a las comunidades en las que operamos. Da&Da Solutions fomenta la participación activa de sus colaboradores en programas de impacto social. Cada empleado dispone de 24 horas anuales remuneradas (3 días hábiles) para dedicarse a actividades de voluntariado en fundaciones u ONGs asociadas a la empresa.

Nuestros programas se centran principalmente en la educación tecnológica, ofreciendo mentoría y talleres de programación gratuitos a jóvenes de sectores vulnerables para reducir la brecha digital.

D.3 Diversidad e Inclusion en Tecnología

La diversidad de perspectivas es el motor de la innovación. Da&Da Solutions tiene un fuerte compromiso con la diversidad e inclusión (D&I). Nos esforzamos por crear equipos donde convivan diferentes géneros, orígenes étnicos, edades y trayectorias profesionales. Contamos con ERGs (Employee Resource Groups) activos para mujeres en tecnología, comunidad LGBTQ+, y neurodiversidad. El equipo de adquisición de talento tiene metas específicas para garantizar que los procesos de selección sean equitativos y libres de sesgos inconscientes.

Anexo E: Marco Metodologico y Adopcion Agile

E.1 Manifiesto Agile Interno

Da&Da Solutions abraza completamente los principios del desarrollo agil de software, adaptandolos a nuestra cultura y necesidades. Entendemos "Agile" no como un conjunto estricto de reuniones, sino como una mentalidad de adaptacion continua, entrega de valor temprano y colaboracion estrecha. Valoramos el software funcionando por encima de la documentacion exhaustiva (aunque, como se detalla en otros apartados, la documentacion justa y necesaria es vital).

E.2 Ciclos de Entrega (Sprints y Kanban)

Los equipos de producto suelen operar en Sprints de dos semanas utilizando metodologias Scrum, con ceremonias de Planning, Daily Stand-up, Review y Retrospectiva. Sin embargo, los equipos de operaciones e infraestructura, asi como los squads que manejan alto volumen de incidencias y soporte no planificado, utilizan Kanban para gestionar su flujo de trabajo, priorizando la reduccion del Work In Progress (WIP) y el Lead Time.

La eleccion del marco especifico se delega a la autonomia de cada equipo, siempre y cuando se cumplan los objetivos de visibilidad (a traves de Jira) y sincronizacion con el resto de la tribu.

E.3 Definition of Ready (DoR) y Definition of Done (DoD)

Para mantener la calidad y predictibilidad, aplicamos de forma estricta los conceptos de DoR y DoD:

- **Definition of Ready (DoR):** Una historia de usuario o tarea no puede entrar a un Sprint o a la columna "In Progress" si no tiene: Criterios de aceptacion claros, dependencias identificadas y resueltas, disenio UX/UI aprobado (si aplica), y ha sido refinada y estimada por el equipo.
- **Definition of Done (DoD):** Un ticket no se considera terminado hasta que: El codigo compila y pasa todos los tests (unitarios y e2e), ha sido revisado (aprobado en PR por al menos 2 pares), ha sido desplegado en el entorno de Staging y validado funcionalmente, la documentacion tecnica esta actualizada, y no introduce nuevas vulnerabilidades (seguridad).

E.4 Ceremonias de Sincronizacion a Nivel Organizacional

A nivel escalado, realizamos ceremonias para alinear a los distintos squads y tribes:

- **Sprint Demo Tribe:** Sesion mensual donde cada equipo presenta el valor entregado y demos en vivo a los stakeholders.
- **Tech Townhall:** Reunion trimestral liderada por el CTO para compartir la vision tecnologica, cambios de arquitectura globales y celebrar logros del equipo de ingenieria.
- **Post-Mortems Transversales:** Cuando un incidente severo afecta a multiples equipos, se realiza un post-mortem conjunto para asegurar que los aprendizajes se distribuyan en toda la organizacion.

Anexo F: Uso Aceptable de Tecnologías y Sistemas

F.1 Dispositivos Corporativos

Los equipos proporcionados por Da&Da Solutions (laptops, teléfonos móviles, monitores) son propiedad de la empresa y se otorgan para uso exclusivamente profesional. Se permite un uso personal incidental siempre que no interfiera con las responsabilidades laborales, no infrinja las políticas de seguridad ni consuma recursos excesivos. Esta prohibida la instalación de software pirata, herramientas de hacking (salvo autorización expresa para equipos de seguridad), mineros de criptomonedas, y clientes P2P para descarga de contenido protegido por derechos de autor.

F.2 Redes Sociales y Comunicación Pública

Alentamos a nuestros colaboradores a ser embajadores de la marca Da&Da Solutions en redes sociales (como LinkedIn, Twitter, blogs técnicos). Sin embargo, deben dejar claro que sus opiniones son personales y no representan posturas oficiales de la compañía, salvo que sean portavoces autorizados. Esta estrictamente prohibido compartir información confidencial sobre clientes, vulnerabilidades de sistemas, estrategias financieras o conflictos internos en plataformas públicas.

F.3 Uso de Herramientas de Inteligencia Artificial (IA)

El uso de herramientas de IA generativa (como ChatGPT, GitHub Copilot, Gemini) está permitido y fomentado para aumentar la productividad, siempre y cuando se adhiera a las siguientes restricciones de seguridad: No se puede ingresar código fuente propietario, credenciales, secretos, datos de clientes o información confidencial de Da&Da Solutions en versiones gratuitas o públicas de estas herramientas, ya que esos datos podrían ser utilizados para entrenar modelos externos. Se deben utilizar únicamente las licencias empresariales provistas por la compañía que garantizan la privacidad de los datos.